

Projet d'Entrepôt de Données

THÈME

Conception et mise en place d'un entrepôt de données pour l'analyse des maladies chroniques les plus fréquentes aux États-Unis à travers un processus ETL, basé sur le dataset officiel U.S. Chronic Disease Indicators (CDI) du CDC (Centers for Disease Control and Prevention).

Ce projet s'inscrit dans une démarche plus large visant à comprendre et anticiper la charge des maladies chroniques en contexte de ressources limitées, à l'image du Cameroun. En l'absence de dataset patient public, fiable et exploitable pour le département de la Menoua ou pour le Cameroun en général, le choix s'est porté sur un dataset international officiel (CDC) afin de garantir la rigueur méthodologique du projet, tout en restant transposable à un contexte camerounais si des données locales venaient à être rendues disponibles (Ministère de la Santé Publique, OMS, Our World in Data).

Pourquoi ce thème est plus précis

- Focus unique : maladies chroniques les plus fréquentes et leurs indicateurs de santé publique.
- Dataset défini : dataset officiel du CDC, disponible directement sur Kaggle, léger et facile à manipuler.
- Objectif clair : analyse de prévalence, de répartition géographique et démographique.
- Scope limité : 17 catégories de pathologies chroniques, données 2001 à aujourd'hui, par État et catégorie démographique (âge, sexe, origine).

1. Objectifs du projet

Le système permet :

- La collecte des données de santé publique sur les maladies chroniques.
- Le stockage centralisé dans un entrepôt de données.
- L'analyse des maladies chroniques les plus fréquentes.
- La détection des pathologies dominantes.
- Le suivi de l'évolution temporelle des indicateurs de santé.
- La génération de tableaux de bord et de statistiques par État et catégorie démographique.

Questions analytiques

- Quelles sont les maladies chroniques les plus fréquentes aux États-Unis ?
- Quelle répartition par sexe, origine ethnique et État ?
- Comment évolue la prévalence des principales maladies chroniques dans le temps ?
- Quels États sont les plus touchés par chaque pathologie ?
- Quelles corrélations entre type de donnée (taux brut, ajusté à l'âge) et pathologie ?

2. Dataset utilisé

Source : Centers for Disease Control and Prevention (CDC) — disponible sur Kaggle

Nom : U.S. Chronic Disease Indicators (CDI)

Lien de téléchargement :

<https://www.kaggle.com/datasets/cdc/chronic-disease>

Caractéristiques du dataset


Attribut	Valeur
Format	CSV
Période	2001 – aujourd'hui (selon publication)
Couverture	50 États américains + territoires
Pathologies	17 catégories (Topic)
Variables principales	YearStart, YearEnd, LocationAbbr, LocationDesc, Topic, Question, DataValueType, DataValue, LowConfidenceLimit, HighConfidenceLimit, StratificationCategory1, Stratification1, GeoLocation

Catégories de pathologies (Topic)

1. Maladies cardiovasculaires
2. Cancer
3. Diabète
4. Asthme
5. Arthrite
6. Maladie rénale chronique
7. Maladie pulmonaire obstructive chronique (BPCO)
8. Santé mentale
9. Nutrition, activité physique et poids
10. Tabac
11. Alcool
12. Santé orale
13. Immunisation
14. Santé reproductive
15. Traumatismes
16. Handicap
17. Surveillance globale (Overarching Conditions)

Note : certaines valeurs sont marquées comme manquantes lorsque l'échantillon est trop faible pour garantir la fiabilité statistique (secret statistique / faible robustesse).

3. Architecture globale du système



Couches de l'architecture

- Couche 1 — Acquisition : dataset CSV téléchargé depuis Kaggle (source officielle CDC).
- Couche 2 — Intégration : ETL pour extraction, transformation et chargement.
- Couche 3 — Stockage : Data Warehouse PostgreSQL avec schéma en étoile.
- Couche 4 — Intelligence : analyses statistiques et requêtes SQL.
- Couche 5 — Visualisation : dashboard Power BI ou Tableau.

4. Structure du Data Warehouse

Table de faits principale : **FACT_DISEASE_INDICATOR**

Champ	Description
indicator_id	ID mesure unique (PK)
time_id	Référence temps (FK)
location_id	Référence État/territoire (FK)
topic_id	Référence catégorie de maladie (FK)
question_id	Référence indicateur précis (FK)
stratification_id	Référence groupe démographique (FK)
data_value	Valeur de l'indicateur (taux, %, etc.)
data_value_type	Type de valeur (taux brut, ajusté à l'âge, etc.)
low_confidence_limit	Borne basse de l'intervalle de confiance

Champ	Description
high_confidence_limit	Borne haute de l'intervalle de confiance

Tables de dimensions

DIM_TIME

- time_id
- year_start
- year_end

DIM_LOCATION

- location_id
- location_abbr
- location_desc
- latitude
- longitude

DIM_TOPIC

- topic_id
- topic_name
- is_chronic
- risk_level

DIM_QUESTION

- question_id
- question_text
- topic_id (FK)

DIM_STRATIFICATION

- stratification_id
- stratification_category (ex: Sexe, Race, Global)
- stratification_value (ex: Homme, Femme, Hispanique)

DIM_DATA_SOURCE

- source_id
- source_name (ex: BRFSS, NVSS, USCS)

Schéma relationnel simplifié

```

DIM_TIME -----|
DIM_LOCATION -----|
DIM_TOPIC -----| ---- FACT_DISEASE_INDICATOR
DIM_QUESTION -----|
DIM_STRATIFICATION ----|
DIM_DATA_SOURCE -----|

```

5. Processus ETL

Extraction

- Téléchargement du dataset CSV depuis Kaggle (cdc/chronic-disease).
- Source : Centers for Disease Control and Prevention (CDC).
- Format : CSV avec 17 catégories de pathologies (Topic).

Transformation

- Suppression des colonnes inutiles (Response, footnotes, stratifications secondaires).
- Conversion de DataValue en valeur numérique (utiliser DataValueAlt si nécessaire).
- Gestion des valeurs manquantes (NULL).
- Normalisation des noms d'États et des catégories de pathologies.
- Séparation de GeoLocation en latitude / longitude.
- Mapping des États vers des identifiants (location_id).

Chargement

- Insertion dans PostgreSQL.
- Chargement d'abord des dimensions.
- Puis chargement de la table de faits.
- Validation des clés étrangères et des volumes.

6. Technologies recommandées

Composant	Technologie	Raison
Base de données	PostgreSQL	Gratuit, robuste, adapté à l'académique
ETL	Python (pandas)	Simple pour nettoyage et traitement
ETL alternatif	JavaScript / n8n	Adapté à votre profil technique
Dashboard	Power BI	Standard de visualisation
Version control	Git + GitHub	Bonnes pratiques
IDE	VS Code	Environnement habituel

7. Analyses possibles

Analyse 1 : Top 10 maladies chroniques les plus fréquentes

```
SELECT
  t.topic_name,
  SUM(f.data_value) AS total_value,
  AVG(f.data_value) AS avg_value
FROM FACT_DISEASE_INDICATOR f
JOIN DIM_TOPIC t ON f.topic_id = t.topic_id
JOIN DIM_TIME ti ON f.time_id = ti.time_id
WHERE ti.year_start = 2020
GROUP BY t.topic_name
```

```
ORDER BY total_value DESC
LIMIT 10;
```

Analyse 2 : Répartition par État

```
SELECT
  l.location_desc,
  t.topic_name,
  AVG(f.data_value) AS avg_value
FROM FACT_DISEASE_INDICATOR f
JOIN DIM_LOCATION l ON f.location_id = l.location_id
JOIN DIM_TOPIC t ON f.topic_id = t.topic_id
GROUP BY l.location_desc, t.topic_name
ORDER BY avg_value DESC;
```

Analyse 3 : Évolution temporelle du diabète

```
SELECT
  ti.year_start,
  AVG(f.data_value) AS avg_value
FROM FACT_DISEASE_INDICATOR f
JOIN DIM_TOPIC t ON f.topic_id = t.topic_id
JOIN DIM_TIME ti ON f.time_id = ti.time_id
WHERE t.topic_name = 'Diabetes'
GROUP BY ti.year_start
ORDER BY ti.year_start;
```

Analyse 4 : Répartition par sexe et origine

```
SELECT
  s.stratification_category,
  s.stratification_value,
  t.topic_name,
  AVG(f.data_value) AS avg_value
FROM FACT_DISEASE_INDICATOR f
JOIN DIM_STRATIFICATION s ON f.stratification_id = s.stratification_id
JOIN DIM_TOPIC t ON f.topic_id = t.topic_id
GROUP BY s.stratification_category, s.stratification_value, t.topic_name
ORDER BY avg_value DESC;
```

8. Dashboard Power BI

Visualisations recommandées :

- Bar chart : top 10 maladies chroniques les plus fréquentes.
- Pie chart : répartition par catégorie de pathologie (Topic).
- Line chart : évolution temporelle par année.
- Map/heatmap : indicateurs par État (utilisant latitude/longitude).
- Table : détails par sexe, origine ethnique.
- KPI cards : valeur moyenne, intervalle de confiance, nombre d'indicateurs suivis.

9. Organisation du projet logiciel

```
chronic-disease-dwh/
├── data/
│   ├── raw/
│   ├── cleaned/
│   ├── exports/
│   └── reports/
```

```

| etl/
|   | extract/
|   | transform/
|   | load/
| warehouse/
|   | schema/
|   | sql/
|   | migrations/
| analytics/
|   | prevalence/
|   | forecasting/
|   | risk_classification/
| api/
|   | controllers/
|   | services/
|   | routes/
| dashboard/
| docker/
| docs/

```

10. Adaptation à votre profil

Vous êtes à l'aise avec JavaScript, n8n et les APIs. Cela permet d'automatiser l'ETL avec un workflow simple :

- Node HTTP Request pour télécharger le CSV depuis Kaggle (API Kaggle).
- Node Code pour nettoyer et transformer les données.
- Node PostgreSQL pour insérer dans l'entrepôt.
- Node Schedule Trigger pour automatiser l'exécution.

11. Résultats attendus

- Liste des maladies chroniques les plus fréquentes aux États-Unis.
- Répartition des indicateurs par catégorie de pathologie.
- Évolution temporelle des principales maladies chroniques.
- Carte géographique des États les plus touchés.
- Répartition démographique par sexe et origine ethnique.
- Publication du dataset transformé sur Kaggle (format entrepôt / star schema).

12. Table de faits complémentaire

FACT_RISK_FACTOR

Champ	Description
risk_id	ID facteur de risque (PK)
location_id	État concerné (FK)
time_id	Référence temps (FK)
topic_id	Pathologie associée (FK)
risk_score	Score de risque calculé

Cette table permet de croiser les indicateurs de prévalence avec un score de risque par État, utile pour les analyses prédictives ci-dessous.

13. Intelligence artificielle et Machine Learning

Sans être le cœur du projet, quelques pistes d'IA peuvent enrichir l'entrepôt de données :

Prévision des tendances

- Modèles de régression ou séries temporelles (ex: ARIMA) pour anticiper l'évolution d'une maladie chronique dans un État donné.

Classification du risque


- Modèle prédisant les États à haut risque pour une pathologie donnée, à partir des indicateurs historiques.

Clustering

- Regroupement des États selon leur profil épidémiologique (k-means) pour identifier des zones similaires.

Ces approches restent optionnelles et peuvent être présentées comme perspective si le temps ne permet pas de les implémenter entièrement.

14. Flux opérationnel



15. KPIs importants

KPI	Description
Prévalence moyenne	Valeur moyenne de l'indicateur par pathologie
Taux ajusté à l'âge	Comparaison entre États indépendamment de la pyramide des âges
Évolution annuelle	Variation de la prévalence d'une année à l'autre
Écart entre États	Différence entre l'État le plus et le moins touché
Score de risque	Indicateur composite calculé pour le suivi prédictif

16. En perspective

Le projet peut être enrichi par :

- L'intégration de données démographiques complémentaires (population par État).
- Une comparaison avec des données de pays similaires (perspective camerounaise dès que des données fiables seront disponibles).
- Un module de prédiction en temps réel des pathologies dominantes.
- Un tableau de bord interactif avec alertes automatiques en cas de hausse anormale d'un indicateur.

17. Références utiles

Dataset principal (Kaggle) : <https://www.kaggle.com/datasets/cdc/chronic-disease>

Source officielle CDC : <https://www.cdc.gov/cdi/index.html>

Data.gov : <https://catalog.data.gov/dataset/u-s-chronic-disease-indicators>

PostgreSQL : <https://www.postgresql.org/docs/>

Power BI : <https://powerbi.microsoft.com/>